

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINARSKI RAD

DETEKCIJA ALZHEIMEROVE BOLESTI MODELIMA STROJNOG UČENJA

Mateja Vuradin

Voditelj: Doc. dr. sc. Jelena Božek

Zagreb, svibanj, 2024.

Detekcija Alzheimerove bolesti modelima strojnog učenja

Mateja Vuradin

Sažetak

Alzheimerova bolest vrlo je česta bolest u današnjem društvu, a lijek za nju još uvijek nije otkriven. Zbog ovog, ali i zbog njezine brze progresivnosti važno je pravovremeno otkrivanje i pružanje pomoći oboljelima. U ovom radu istražena je mogućnost detekcije faza bolesti uz tehnike dubokog učenja, tj. konvolucijske neuronske mreže. Korištene su javno dostupne MR slike s Kaggle-a. Postignuta je točnost od 99.06% uz jednostavnu konvolucijsku mrežu.

Ključne riječi: Alzheimerova bolest;detekcija;duboko učenje

Sadržaj

Sažetak	1
1. Uvod	3
2. Korištene metode	4
2.1. Duboko učenje	4
2.2. Konvolucijske neuronske mreže	4
3. Rezultati i rasprava	5
3.1. Korišteni podaci	5
3.2. Priprema podataka	6
3.3. Model	7
3.4. Rezultati	8
3.5. Usporedba sa srodnim istraživanjima	9
4. Zaključak	11
Literatura	12

1. Uvod

Alzheimerova bolest najčešća je bolest demencije, a prepoznatljiva je po gubitku pamćenja. Razlog simptoma je odumiranje neurona u mozgu i smanjenje volumena mozga. Bolest najčešće pogađa starije osobe [1].

Postoji više podjela faza bolesti, a detekcija je važna jer osobe većinom žive samo još 4 do 8 godina nakon dijagnoze. Jedna od glavnih podjela je na ranu, srednju i kasnu fazu. U ranoj fazi simptomi nisu zabrinjavajući, ali se mogu očitovati u zaboravu imena, gubljenju predmeta i poteškoćama u planiranju. Srednja faza dolazi uz jače poteškoće poput gubitka u prostoru i vremenu, zaborava osobnih informacija, promjena u raspoloženju i problema sa spavanjem. Oboljeli u posljednjoj fazi imaju problema s hodaњem, govorenjem, gutanjem i često trebaju posebnu skrb [2].

Unatoč procijenjenom broju od 78 milijuna oboljelih do 2030. godine, i dalje ne postoji lijek ili tretman za potpun oporavak. Postoji tek par lijekova i promjena prehrane koji mogu usporiti napredak bolesti [3].

Rješenje koje bi omogućilo bržu dijagnozu i raniju detekciju bolesti je strojno učenje. Kako se radi o MR slikama, ovaj rad istražuje primjenu dubokog učenja za detekciju faze bolesti.

2. Korištene metode


2.1. Duboko učenje

Duboko učenje je podgrana strojnog učenja, a osnovna jedinica rada su neuronske mreže. One oponašaju rad ljudskog mozga.

Osnovna pretpostavka dubokog učenja je velika količina podataka i mreže s više od tri sloja. Cilj neuronskih mreža je prepoznati uzorke i veze u podacima te napraviti predikciju [4].

2.2. Konvolucijske neuronske mreže

Neuronske mreže sastoje se najčešće od tri sloja: ulaznog, skrivenih i izlaznog. Konvolucijske mreže imaju malo kompliciraniju strukturu, tj. koriste se ulazni, konvolucijski sloj, sloj sažimanja, potpuno povezani i izlazni sloj (vidi sliku 2.1.).




Slika 2.1. Arhitektura konvolucijske mreže [5]

Glavna zadaća konvolucijskog sloja je ekstrakcija važnih obilježja, tj. on djeluje poput filtra. Nelinearnost se može dodati aktivacijskim slojem. Sloj sažimanja služi za smanjenje dimenzija i sprječava prenaučenosť. Konačnu klasifikaciju omogućuje završni potpuno povezani sloj [5].

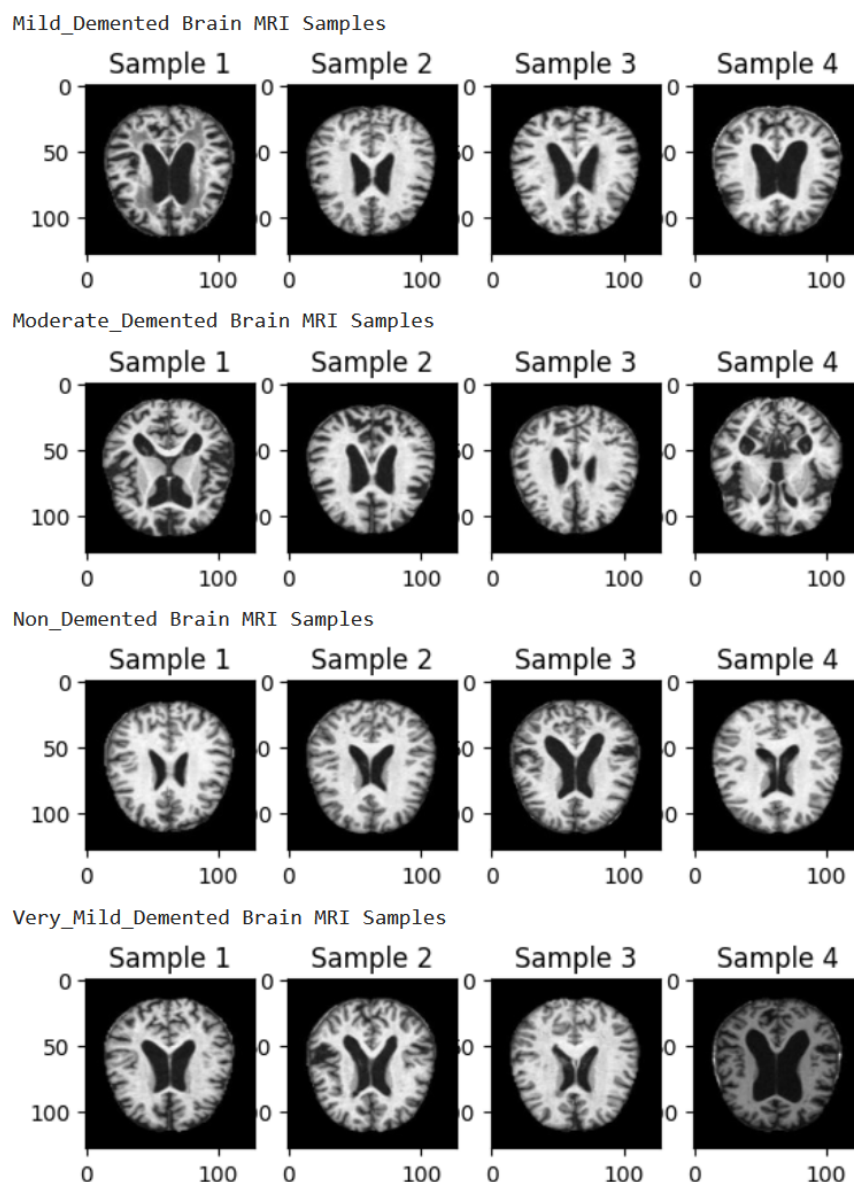
3. Rezultati i rasprava

3.1. Korišteni podaci

Korišteni podaci preuzeti su s javno dostupne baze podataka na Kaggle stranici[6]. Ukupno je 6400 MR slika veličine 128x128 piksela (točnije 6400 aksijalnih presjeka). Postoje četiri klase prema kojima su slike podijeljene: nedementni, vrlo blago dementni, blago dementni, umjereno dementni (Vidi sliku 3.2.). Klase nisu jednako zastupljene, već prema sljedećoj distribuciji:



Slika 3.1. Prikaz distribucije klasa



Slika 3.2. Prikaz MR slike iz pojedine klase

3.2. Priprema podataka

Neuronske mreže često rade bolje kada su podaci normalizirani, tj. skalirani na vrijednosti između 0 i 1. Ovo omogućuje bolje prepoznavanje uzoraka. Zbog toga je provedeno skaliranje intervala 0 do 255 na 0 do 1 [7].

Osim toga, podaci su podijeljeni na skup za treniranje, validaciju i testiranje. Za treniranje je uzeto 80% podataka, za validaciju 10%, a za testiranje također 10%. Koristio se batch veličine 32.

Nebalansiranost klasa može također predstaviti veliki problem u učenju mreže, oso-

bito jer je nedementnih ispitanika značajno više nego vrlo dementnih. Naime, model može favorizirati brojnije klase jer one više utječu na gubitak. Ovakav model postaje prenaučan i loše generalizira. Zbog toga je prije treniranja provedeno predviđanje težina pojedine klase, tj. brojnim klasama je pridijeljena manja težina [8]. Formula koja se koristi za izračun težine pojedine klase je:

$$w_i = \frac{n_{samples}}{n_{samples_in_class} * n_{classes}} \quad (3.1)$$

3.3. Model

Za predikciju klase stadija demencije korišten je relativno jednostavan model, tj. konvolucijska mreža. Mreža se sastojala od 3 konvolucijska sloja između kojih se koristio sloj maksimalnog sažimanja te 3 potpuno povezana sloja na kraju (Vidi sliku 3.3.).

Model: "sequential"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 126, 126, 16)	448
max_pooling2d (MaxPooling2D)	(None, 63, 63, 16)	0
conv2d_1 (Conv2D)	(None, 61, 61, 32)	4640
max_pooling2d_1 (MaxPooling2D)	(None, 30, 30, 32)	0
conv2d_2 (Conv2D)	(None, 28, 28, 128)	36992
max_pooling2d_2 (MaxPooling2D)	(None, 14, 14, 128)	0
flatten (Flatten)	(None, 25088)	0
dense (Dense)	(None, 128)	3211392
dense_1 (Dense)	(None, 64)	8256
dense_2 (Dense)	(None, 4)	260

=====
Total params: 3261988 (12.44 MB)
Trainable params: 3261988 (12.44 MB)
Non-trainable params: 0 (0.00 Byte)

Slika 3.3. Prikaz korištene neuronske mreže

Optimizacijska je provedena uz Adam algoritam, a nelinearnost dodana ReLu akti-


vacijskom funkcijom. Izlazna klasa je predviđena softmax funkcijom.

Uz konvolucijski model, definirane su i dvije funkcije koje se pozivaju tijekom treniranja. Prva funkcija se izvodi nakon svake epohe i osigurava spremanje najboljeg modela, tj. onog koji osigurava najveću točnost validacijskog skupa. Definirano je izvođenje 20 epoha, ali se koristi i funkcija za rano zaustavljanje koja zaustavlja treniranje kada se gubitak skupa za validaciju počne povećavati u uzastopnih par, tj. 5 epoha.

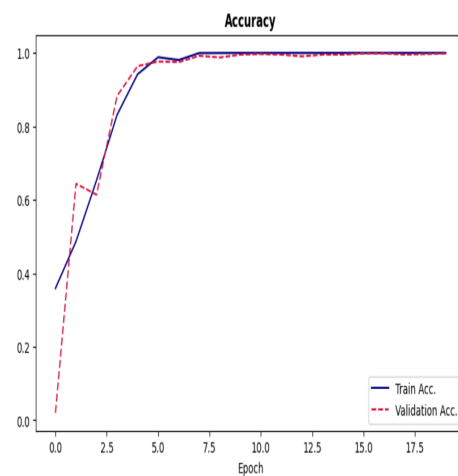
S ovako pripremljenim podacima, težinama, konvolucijskom mrežom i pozivajućim funkcijama, pokrenuto je treniranje podataka.

3.4. Rezultati

Treniranje je provedeno na 20 epoha. Gubitak je vrlo brzo konvergirao prema nuli. Također, već oko pete epohe je vidljivo da je i točnost oba skupa (za treniranje i validaciju) blizu 100



Slika 3.4. Gubitak na skupu za treniranje i validaciju



Slika 3.5. Točnost na skupu za treniranje i validaciju

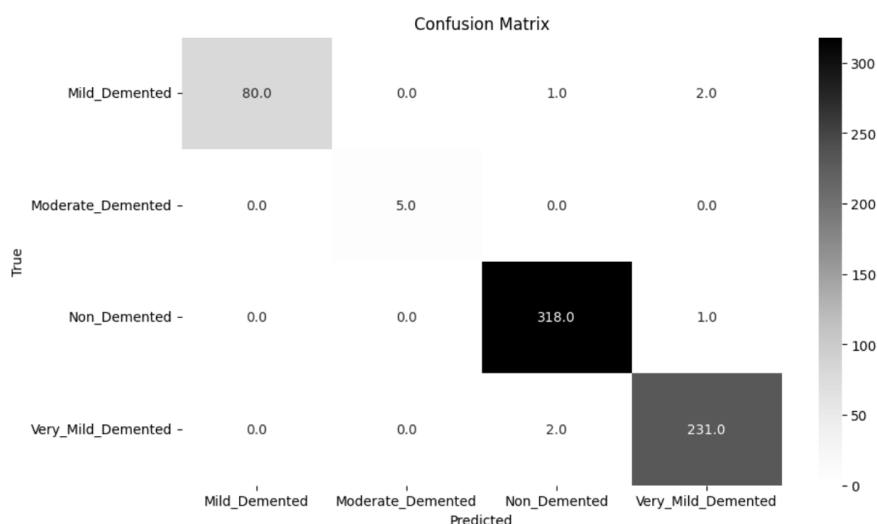
Nakon treniranja provedeno je i testiranje na 10% podataka, tj. na 640 MR slika. Dobivena je točnost od 99.06%. Osim točnosti provjerene su i mjere poput preciznosti, odziv i f1 mjere (vidi sliku 3.6.). Kod nebalansiranih klasa točnost može biti velika te dovodi do krivih zaključaka, ali zbog korištenja težina klasa vidljivo je da su i ostale mjere poput f1 mjere također vrlo visoke za sve klase.

Pogledom na matricu zabune vidljivo je svega par krivo svrstanih primjera (vidi sliku

	precision	recall	f1-score	support
Mild_Demented	1.00	0.96	0.98	83
Moderate_Demented	1.00	1.00	1.00	5
Non_Demented	0.99	1.00	0.99	319
Very_Mild_Demented	0.99	0.99	0.99	233

Slika 3.6. Mjere točnosti za skup za testiranje

3.7.). Naime, postoje blago dementni slučajevi koji su svrstani u nedementne ili u vrlo blago dementne. Također postoje nedementni svrstani u vrlo blago dementne i obrnuto. Problem su slučajevi proglašavanja bolesnih u nedementne. Ovaj problem bi se mogao riješiti u sljedećim istraživanjima uvođenjem veće "kazne" na krivo klasificirane dementne jer je bolje da proglasimo nekoga bolesnim i provedemo daljnja istraživanja nego da ga krivo proglasimo zdravim¹.



Slika 3.7. Matrica zabune za skup za testiranje

3.5. Usporedba sa srodnim istraživanjima

Brojna istraživanja provedena su na OASIS² i ADNI³ bazama podataka. OASIS baza sadrži podatke o 373 skena, a često je promatrana u tabličnom obliku te koristi brojne druge informacije uz podatke iz MR slika (dob, rezultate na testovima itd.). Zbog ovog se predikcije na njoj često rade i samo algoritmima strojnog učenja [9]. ADNI baza sadrži MRI i PET skenove, ali i različite krvne markere. Na ovoj bazi su provedena neka od sljedećih

¹kod dostupan na <https://github.com/matejaVuradin/seminar2>

²<https://sites.wustl.edu/oasisbrains/>

³<https://adni.loni.usc.edu/>

multiklasnih istraživanja (vidi tablicu 3.1.) koja koriste skenove od 300 ispitanika, ali s različitim brojem skenova i često korištenjem augmentacije za povećanje skupa podataka. Svi priloženi radovi imaju manju postignutu točnost od implementacije u ovom radu.

autor	tip podataka	model	točnost
Biswas, R., Gini J, R. [10]	2D	ResNet-101	98.37%
Helaly, H.A. et al.[11]	2D	CNN	93.61%
	3D	CNN	95.17%
Hosseini-Asl, E. et al. [12]	3D	3D-CNN	89.1%
Khan, R. et al. [13]	2D	transfer učenje	98.47%

Tablica 3.1. Rezultati postojećih radova

Rama Ganesh, C H. S. C. A et al. [14] koristili su također Kaggle skup podataka i CNN, ali postigli točnost od samo 75%. Shaymaa E. Sorour et al. [15] su uspjeli uz LSTM mrežu postići veću točnost (99.92%).

Iz ovih rezultata otvara se pitanje kvalitete predikcije klase korištenjem 2D isječaka nasuprot cijelih 3D skenova. Premda korištenjem samo aksijalnog presjeka dolazi do gubitka informacija, priloženi radovi (kao i ovaj rad) uspjeli su bolje predvidjeti klase nego kada se koristi cijela MR slika.

4. Zaključak

Alzheimerova bolest predstavlja veliki problem društva, a nepostojanje lijekova samo pridonosi ozbiljnosti situacije. Duboko učenje pokazalo se kao odlična metoda koja bi mogla pomoći doktorima i ubrzati proces detekcije bolesti i njenog stadija, bez potreba za detaljnijim mjerenjima.

Ovo istraživanje provedeno je na 6400 skenova, a donosi točnost na skupu za testiranje od čak 99.06%. Ovo su bolji rezultati od onih postignutih na mnogo poznatijim skupovima podataka (OASIS i ADNI) uz mnogo kompliciranije tehnike. Premda je ovo vrlo visoka točnost, postoje radovi koji su postigli bolju poput Shaymaa E. Sorour et al. [15] uz nešto sofisticiranije mreže (LSTM).

Moguće je poboljšanje rada, npr. dodatna augmentacija i pretprocesiranje podataka. Također, model bi se mogao unaprijediti već spomenutim težinama krive klasifikacije, ali i dubljim slojevima ili jednostavno korištenjem LSTM-a. Osim poboljšanja, trebala bi se dublje razmotriti i primjena 3D MR slika nasuprot one 2D, tj. aksijalnih presjeka.

Literatura

- [1] M. P. Mattson, "Pathways towards and away from alzheimer's disease", *Nature* 430, 631–639, 2004.
- [2] A. association, <https://www.alz.org/alzheimers-dementia/stages>, [mrežno; stranica posjećena:svibanj 2024.].
- [3] A. D. International, <https://www.alzint.org/about/dementia-facts-figures/dementia-statistics/>, [mrežno; stranica posjećena:svibanj 2024.].
- [4] L. Alzubaidi, J. Zhang, A. J. Humaidi, A. Al-Dujaili, Y. Duan, O. Al-Shamma, J. Santamaría, M. A. Fadhel, M. Al-Amidie, i L. Farhan, "Review of deep learning: concepts, cnn architectures, challenges, applications, future directions", *Big Data*, 2021.
- [5] I. to Convolution Neural Network, <https://www.geeksforgeeks.org/introduction-convolution-neural-network/>, [mrežno; stranica posjećena:svibanj 2024.].
- [6] <https://www.kaggle.com/datasets/sachinkumar413/alzheimer-mri-dataset>, [mrežno; stranica posjećena:svibanj 2024.].
- [7] J. F. Adrien Depeursinge i O. S. Al-Kadi, *Biomedical Texture Analysis*. Academic Press, 2018.
- [8] J. M. Johnson i T. M. Khoshgoftaar, "Survey on deep learning with class imbalance." *Big Data*, sv. 6, 2019. <https://doi.org/https://doi.org/10.1186/s40537-019-0192-5>
- [9] M. Vuradin, "Predikcija rane faze alzheimerove bolesti modelima strojnog učenja", seminar1.

- [10] D. Prakash, N. Madusanka, S. Bhattacharjee, C. Kim, H. Park, i H. Choi, “Diagnosing alzheimer’s disease based on multiclass mri scans using transfer learning techniques”, *Curr Med Imaging*, 2021.
- [11] H. Helaly, M. Badawy, i A. Haikal, “Deep learning approach for early detection of alzheimer’s disease”, *Cogn Comput*, sv. 14, 2022.
- [12] E. Hosseini-Asl, R. Keynton, i A. El-Baz, “Alzheimer’s disease diagnostics by adaptation of 3d convolutional network”, 2016.
- [13] R. Khan, S. Akbar, A. Mehmood, F. Shahid, K. Munir, N. Ilyas, M. Asif, i Z. Zheng, “A transfer learning approach for multiclass classification of alzheimer’s disease using mri images”, *Front Neurosci*, 2023.
- [14] C. H. S. C. A. Rama Ganesh, G. Sri Nithin, S. Akshay, i T. Venkat Narayana Rao, “Multi class alzheimer disease detection using deep learning techniques”, u 2022 *International Conference on Decision Aid Sciences and Applications (DASA)*, 2022., str. 470–474. <https://doi.org/10.1109/DASA54658.2022.9765267>
- [15] S. E. Sorour, A. A. A. El-Mageed, K. M. Albarrak, A. K. Alnaim, A. A. Wafa, i E. El-Shafeiy, “Classification of alzheimer’s disease using mri data based on deep learning techniques”, *Journal of King Saud University - Computer and Information Sciences*, sv. 36, br. 2, str. 101940, 2024. <https://doi.org/https://doi.org/10.1016/j.jksuci.2024.101940>